

Evaluación técnica

Profesional en Ciencia de Datos

*Calidad del dato, estándares, computación en la nube
y análisis de series de tiempo hidrometeorológicas*

Elaborado por	Equipo de Calidad de Datos, SIATA
Rol evaluado	Profesional de Ciencia de Datos
Versión	1.0, octubre de 2026
Duración	2 horas: inicio 9:00 a. m., entrega 11:00 a. m.
Sustentación	Máximo 10 minutos por candidato
Estructura	Parte 1: Conceptual y arquitectura (40 %) Parte 2: Programación y análisis de datos (60 %)

Índice

1. Propósito y lineamientos generales	2
1.1. Estructura	2
1.2. Reglas	2
1.3. Entrega y sustentación	3
1.4. Entregables	3
2. Parte 1: Conceptual, estándares y arquitectura	3
2.1. Calidad de los datos: marco conceptual [20 pts]	3
2.2. Indicadores de calidad de los datos entregados [25 pts]	4
2.3. Normas y estándares [15 pts]	5
2.4. Computación en la nube, modelos híbridos y repositorios [15 pts]	5
2.5. Auditoría del repositorio de datos de SIATA [25 pts]	6
3. Parte 2: Programación y análisis de datos	8
3.1. Contexto y datos	8
3.2. Tarea A: Análisis exploratorio de datos (EDA) [15 pts]	8
3.3. Tarea B: Modelado de series de tiempo [20 pts]	8
3.4. Tarea C: Detección de anomalías [15 pts]	9
3.5. Tarea D: Correlaciones y relaciones [10 pts]	9
3.6. Tarea E: Reproducibilidad, ingeniería y comunicación [20 pts]	10
3.7. Tarea F: Prototipo de dashboard [20 pts]	10
4. Rúbrica de evaluación	12
4.1. Ponderación general	12
4.2. Niveles de desempeño por criterio	12
4.3. Señales de alerta (<i>red flags</i>)	12
4.4. Sustentación (máximo 10 minutos)	12

1 Propósito y lineamientos generales

Esta evaluación mide la capacidad del candidato para *garantizar, medir y comunicar la calidad* de los datos ambientales que SIATA entrega a la ciudadanía, a las entidades y a la comunidad científica. No se busca la solución más sofisticada, sino el criterio técnico, el rigor metodológico y la capacidad de justificar decisiones.

1.1 Estructura

Parte	Contenido	Tiempo sugerido	Peso
1	Conceptual, estándares, nube, repositorios y auditoría del repositorio de datos de SIATA	Aprox. 40 minutos	40 %
2	Programación y análisis: EDA, series de tiempo, anomalías y correlaciones sobre 4 archivos, y prototipo de dashboard	Aprox. 80 minutos	60 %

1.2 Reglas

- **Duración total: 2 horas.** La prueba inicia a las 9:00 a. m. y finaliza a las 11:00 a. m. (ambas partes en una sola sesión).
- Los candidatos pueden usar **todos los recursos que consideren necesarios** (documentación, normas, bibliografía, buscadores, herramientas de inteligencia artificial, bibliotecas y software de su preferencia). Se recomienda indicar en el *README* las herramientas utilizadas y qué validó por su cuenta, pues deberá sustentarlo.
- Dado el tiempo limitado, **se valora la priorización**: es preferible un resultado parcial, correcto y bien explicado que uno extenso y superficial.
- Toda afirmación cuantitativa debe ser reproducible a partir del código entregado.
- Cuando el enunciado sea ambiguo, **documente su supuesto** en lugar de asumir que existe una única respuesta correcta.
- Se valora más un hallazgo bien sustentado que diez hallazgos sin evidencia.
- Los datos entregados son de uso exclusivo para esta evaluación.

1.3 Entrega y sustentación

Hito	Condición
Inicio	9:00 a. m.
Cierre de la prueba	11:00 a. m.
Medio de entrega	A las 11:00 a. m. cada candidato envía por correo electrónico el enlace del repositorio público de GitHub a jipadillab@eafit.edu.co
Verificación	Solo se evaluará el contenido de los <i>commits</i> realizados antes de las 11:00 a. m.; el repositorio debe estar público al momento del envío
Sustentación	Máximo 10 minutos por candidato, posterior a la evaluación
Orden de turnos	Según el orden de recepción de los correos : la primera persona en enviar su solución sustenta primero, y así sucesivamente

1.4 Entregables

1. Respuestas de la Parte 1 en formato Markdown, dentro del repositorio (carpeta *parte1/*).
2. **Repositorio público en GitHub** con la solución de la Parte 2 (código, dependencias y salidas).
3. Resumen ejecutivo de la Parte 2 (máximo 2 páginas, en el *README* o en PDF) dirigido a un jefe de área no especialista en estadística.
4. Borrador o prototipo de *dashboard* que presente los resultados del análisis (Tarea F), ejecutable desde el repositorio o accesible mediante un enlace, con capturas de pantalla en el informe.

2 Parte 1: Conceptual, estándares y arquitectura

2.1 Calidad de los datos: marco conceptual

[20 pts]

Pregunta 1.1. Explique con sus propias palabras qué significa que un dato hidrometeorológico *tenga calidad*. Su respuesta debe:

- (a) Definir calidad como *aptitud para el uso* y vincularla al menos con tres dimensiones tomadas de un marco formal (por ejemplo DAMA-DMBOK, ISO/IEC 25012 o ISO 8000).
- (b) Distinguir entre calidad del dato, calidad del instrumento (exactitud, calibración, trazabilidad) y calidad del proceso.
- (c) Explicar por qué un dato *físicamente plausible* no es necesariamente un dato *correcto*.

Pregunta 1.2. Complete la siguiente tabla y justifique en un párrafo la diferencia entre cada nivel. Incluya qué se espera que *cambie* del dato al pasar de un nivel al siguiente.

Aspecto	Dato crudo	Dato validado con metadatos	Dato para consumo del usuario
Definición			
Unidades y resolución			
Banderas de calidad			
Metadatos mínimos			
Tratamiento de faltantes			
Usuario típico			
Riesgo de mal uso			

Qué se busca

Se espera que el candidato mencione, entre otros elementos: identificador y coordenadas de la estación, altura del sensor, unidades, resolución, intervalo de muestreo, zona horaria, versión del algoritmo de validación, diccionario de banderas, historial de mantenimiento y calibración, y licencia de uso (referencia a los estándares de metadatos de WIGOS y a ISO 19115).

2.2 Indicadores de calidad de los datos entregados

[25 pts]

Pregunta 1.3. Proponga **tres (3) indicadores de calidad** aplicables a los datos que SIATA publica. Para cada uno, complete la ficha técnica:

Campo	Descripción
Nombre y dimensión de calidad	
Objetivo y pregunta que responde	
Fórmula (con definición de cada término)	
Unidad de medida y periodicidad de cálculo	
Fuente de datos y nivel de agregación (estación, red, variable)	
Umbrales de semáforo (aceptable, alerta, crítico) y su justificación	
Responsable y acción correctiva asociada	
Limitaciones y posibles sesgos del indicador	

Criterios de la pregunta. Los indicadores deben ser *medibles*, *automatizables*, *accionables* y *comparables entre variables y estaciones*. Se penalizan indicadores redundantes entre sí (por ejemplo, dos formas de medir completitud). Los tres deben cubrir dimensiones distintas.

Pregunta 1.4. Para uno de los tres indicadores, escriba el pseudocódigo o la consulta (SQL o Python) que lo calcula sobre una tabla con columnas *codigo*, *fecha_hora*, *valor* y *calidad*, e indique cómo trataría las estaciones con intervalos de muestreo distintos.

2.3 Normas y estándares

[15 pts]

Pregunta 1.5. Para cada grupo de estándares, indique en **una frase** qué práctica concreta aplicaría SIATA.

Estándar	Tema	Aplicación en SIATA
DAMA-DMBOK 2	Gobierno y dimensiones de calidad	
ISO 8000 e ISO/IEC 25012 y 25024	Modelo y medición de calidad del dato	
ISO 19115 y 19157	Metadatos y calidad geoespacial	
OMM No. 8 y No. 100	Calidad de instrumentos y de datos climatológicos	
OMM No. 1131 y metadatos WIGOS	Gestión de calidad y metadatos de estaciones	
Principios FAIR	Acceso y reutilización de datos	

Pregunta 1.6. Describa una cadena de control de calidad de datos meteorológicos en al menos cuatro etapas (por ejemplo: formato y completitud, rango, coherencia temporal y persistencia, coherencia interna entre variables, coherencia espacial). Para cada etapa indique una prueba concreta, su umbral y qué bandera asignaría.

2.4 Computación en la nube, modelos híbridos y repositorios

[15 pts]

Pregunta 1.7 (arquitectura en la nube e híbrida). SIATA recibe datos por minuto desde cientos de estaciones y sus alertas son críticas para la ciudad. Diseñe una arquitectura de datos para ingesta, validación, almacenamiento y publicación, sobre la nube de su preferencia (AWS, Google Cloud o Azure) o sobre un **modelo híbrido** (infraestructura propia *on-premise* más nube). Entregue un diagrama y una justificación que cubra:

- Conceptos base:** modelos de servicio (IaaS, PaaS, SaaS) y de despliegue (pública, privada, híbrida), y cuál elegiría para SIATA y por qué.
- Capas de almacenamiento (crudo, validado, producto) y formatos (por ejemplo Parquet, particionamiento).
- Orquestación, cómputo y estrategia de reprocesamiento (idempotencia).
- Modelo híbrido:** qué componentes mantendría *on-premise* y cuáles llevaría a la nube (ver tabla), cómo sincroniza ambos entornos y cómo garantiza la continuidad operativa si se cae el enlace o el proveedor.
- Repositorio de calidad en la nube:** cómo dispondría el catálogo de datos, el diccionario de variables y banderas, las reglas de validación versionadas, el linaje, los indicadores de calidad

y las salidas para el usuario (API y datos abiertos), con control de acceso por rol, retención, respaldo y recuperación ante desastres (metas RPO y RTO).

- (f) Seguridad y cumplimiento: gestión de identidades, cifrado, principio de mínimo privilegio y normativa aplicable en Colombia (por ejemplo, protección de datos personales).
- (g) Observabilidad: monitoreo de la calidad y alertas ante falla de estaciones.
- (h) Costos: estimación cualitativa (incluidos los costos de salida de datos) y tres decisiones para controlarlos.
- (i) Infraestructura como código y despliegue continuo.

Complete esta tabla para el ítem (d):

Componente	On-premise	Nube	Justificación
Adquisición y <i>buffer</i> local en estación o centro de datos Datos crudos históricos Validación y control de calidad Repositorio de calidad (catálogo, banderas, reglas) Publicación para usuarios (API, datos abiertos) Modelos y alertas de operación crítica			

Pregunta 1.8 (repositorios). Describa el flujo de trabajo con Git que implementaría para un equipo de cinco personas que mantiene código de validación de datos. Incluya estrategia de ramas, convención de *commits*, revisión de código, pruebas automáticas (CI), gestión de versiones del algoritmo de calidad, manejo de datos grandes y de secretos, y qué debe contener un buen *README*.

2.5 Auditoría del repositorio de datos de SIATA

[25 pts]

Pregunta 1.9. Ingrese al repositorio o portal de datos de SIATA y revise la forma en que se descubren, describen, descargan y documentan los datos. Entregue un informe breve (máximo dos páginas) que responda:

- (a) ¿Qué **cambiaría**? Elementos existentes que deben modificarse.
- (b) ¿Qué **falta**? Capacidades, metadatos, documentación o controles ausentes.

- (c) **¿Qué sobra?** Redundancias, información confusa o procesos que no agregan valor.
- (d) **¿Cómo lo mejoraría?** Plan priorizado en una matriz de impacto frente a esfuerzo, con horizonte de 30, 90 y 180 días.

Cada hallazgo debe incluir evidencia (captura, enlace o descripción reproducible) y el estándar o principio que respalda la recomendación.

Sobre la evaluación de esta pregunta

No existe una lista cerrada de respuestas correctas. Se valora la capacidad de observar el servicio desde la perspectiva de distintos usuarios (ciudadano, investigador, desarrollador), de priorizar con criterio y de proponer mejoras viables.

3 Parte 2: Programación y análisis de datos

3.1 Contexto y datos

Se entregan cuatro archivos CSV con registros de **una estación por tipo de sensor**, con frecuencia nominal de un minuto, entre el 1 de diciembre de 2025 y el 30 de abril de 2026. Los conjuntos presentan dinámicas, resoluciones y problemas distintos. Parte del trabajo consiste en descubrirlos.

Archivo	Estación	Columnas	Filas
<i>Estacion_meteorologica_367</i>	367	<i>h, t, pr, vv, vv_max, dv, dv_max, p, calidad</i>	217 397
<i>Estacion_nivel_803</i>	803	<i>nivel, calidad</i>	217 318
<i>Estacion_piranometro_6004</i>	6004	<i>radiacion, calidad</i>	214 824
<i>Estacion_pluviometrica_35</i>	35	<i>p1, p2, calidad</i>	217 440

Todos incluyen *codigo* y *fecha_hora*. No se entrega diccionario de datos: **reconstruirlo y documentar sus supuestos forma parte de la prueba.**

3.2 Tarea A: Análisis exploratorio de datos (EDA)

[15 pts]

Realice un EDA *por conjunto de datos* y uno *comparativo*. Como mínimo:

- A1. Perfilamiento: tipos, rangos, nulos, valores centinela, duplicados, orden y regularidad del índice temporal.
- A2. Completitud temporal: cantidad y duración de huecos, distribución por hora del día y por mes.
- A3. Distribución de cada variable y de la columna *calidad* (frecuencia de cada código y su relación con los valores).
- A4. Ciclos diurnos y semanales, estacionalidad y tendencia.
- A5. Consistencia física e interna entre columnas de un mismo archivo.
- A6. Tabla de hallazgos priorizada: problema, evidencia, impacto y recomendación.

3.3 Tarea B: Modelado de series de tiempo

[20 pts]

Seleccione **al menos una variable por archivo** (justifique su elección) y:

- B1. Defina y justifique el *preprocesamiento* (regularización del índice, tratamiento de faltantes y de valores centinela, agregación temporal).
- B2. Descomponga la serie (por ejemplo STL) y analice estacionariedad y autocorrelación.
- B3. Ajuste **al menos dos enfoques** comparables (por ejemplo, un modelo estadístico tipo ETS o SARIMA y un modelo basado en aprendizaje automático con variables rezagadas). Para variables con alta intermitencia, como la lluvia, justifique un enfoque adecuado.
- B4. Evalúe con **validación de origen móvil** (*rolling origin*), sin fuga de información, con

métricas apropiadas (MAE, RMSE y una métrica escalada como MASE) y contra un modelo de referencia ingenuo.

B5. Cuantifique la incertidumbre del pronóstico (intervalos o cuantiles) y discuta su calibración.

B6. Concluya: qué modelo recomendaría para operación y bajo qué supuestos fallaría.

3.4 Tarea C: Detección de anomalías

[15 pts]

C1. Implemente **reglas deterministas** de control de calidad (rango físico, salto máximo, persistencia o valor congelado, coherencia entre variables).

C2. Implemente **métodos estadísticos o de aprendizaje automático** (por ejemplo residuos de descomposición con MAD, Isolation Forest, detección de cambios de régimen).

C3. Compare ambos enfoques entre sí y contra la columna *calidad* entregada, tratándola como *etiqueta débil* (no como verdad absoluta). Reporte precisión, exhaustividad y casos de desacuerdo.

C4. Clasifique cada anomalía relevante: falla de sensor, falla de comunicación, problema de configuración o evento físico real. Justifique por qué es importante *no eliminar* un evento extremo real.

C5. Proponga un esquema de banderas de calidad y un diccionario para los códigos de *calidad* que logró inferir.

3.5 Tarea D: Correlaciones y relaciones

[10 pts]

D1. Analice las relaciones *entre columnas de cada dataset* (por ejemplo entre medidas redundantes o derivadas).

D2. Analice las relaciones *entre datasets* considerando la resolución temporal común, el desfase (*lags*) y la posible distancia entre estaciones.

D3. Distinga correlación espuria (por ejemplo, producida por un ciclo diurno compartido) de relación informativa: repita el análisis sobre series desestacionalizadas o diferenciadas.

D4. Use al menos una medida distinta de Pearson (Spearman, información mutua o correlación cruzada) y justifique cuándo es preferible.

D5. Formule una hipótesis hidrometeorológica y contrástela con los datos.

3.6 Tarea E: Reproducibilidad, ingeniería y comunicación

[20 pts]

- E1. Repositorio Git con historial de *commits* legible, *README*, instrucciones de ejecución y gestión de dependencias (por ejemplo *requirements.txt* o *environment.yml*).
- E2. Código modular (funciones o paquetes, no solo *notebooks*), con al menos un conjunto de pruebas automáticas para las reglas de calidad.
- E3. Los datos crudos no se modifican: toda transformación queda en código y genera salidas versionables.
- E4. Propuesta breve (media página) de cómo llevaría su pipeline a producción en la nube.
- E5. Resumen ejecutivo de máximo 2 páginas con visualizaciones claras, hallazgos priorizados y recomendaciones accionables.

3.7 Tarea F: Prototipo de dashboard

[20 pts]

Diseñe y construya un **borrador funcional de dashboard** que permita a un usuario no técnico explorar los resultados de las Tareas A a D. Puede usar la herramienta de su preferencia (por ejemplo Streamlit, Dash, Panel, Grafana, Power BI, Looker Studio o una página web estática); se valora más el diseño y el criterio que la herramienta. Debe incluir:

- F1. **Boceto previo** (*wireframe*, a mano o digital) con la audiencia objetivo, las preguntas que el dashboard responde y la jerarquía de la información.
- F2. **Vista de salud de la red**: estado por estación y variable, con al menos los tres indicadores de calidad propuestos en la Pregunta 1.3 (completitud, proporción de datos válidos y un tercero a su elección), con semáforo y umbrales explícitos.
- F3. **Vista de series de tiempo**: serie con selector de estación, variable y rango de fechas; marcación visible de huecos, anomalías detectadas y banderas de calidad; pronóstico con su intervalo de incertidumbre.
- F4. **Vista de anomalías**: tabla filtrable de eventos con su tipo (falla de sensor, comunicación, configuración o evento físico real), la regla o modelo que la detectó y la severidad.
- F5. **Vista de relaciones**: matriz o gráfico de correlaciones y correlación cruzada con rezagos, indicando si se calcularon sobre series desestacionalizadas.
- F6. **Transparencia**: una sección o panel de ayuda con el diccionario de variables y banderas, las unidades, la fuente de los datos, la fecha de actualización y las limitaciones conocidas.
- F7. **Ejecución reproducible**: instrucciones para lanzarlo desde el repositorio (un solo comando) y, de forma opcional, una propuesta de despliegue en la nube.

Criterios de diseño que se evaluarán

Claridad visual y relación datos-tinta; elección adecuada del tipo de gráfico para cada pregunta; escalas, unidades y ejes honestos (sin truncamientos engañosos); uso accesible del color (por ejemplo, aptitud para personas con daltonismo y no depender solo del rojo y verde); manejo

correcto de la dirección del viento (variable circular) y de la lluvia (variable intermitente); tiempos de carga razonables con el volumen de datos (más de 200 000 registros por archivo); y comunicación de la incertidumbre. Se acepta un prototipo incompleto, siempre que el candidato explique qué construiría con más tiempo.

4 Rúbrica de evaluación

4.1 Ponderación general

Componente	Puntos internos	Peso final
Parte 1: Conceptual, estándares, nube y auditoría	100	40 %
Parte 2: Programación y análisis	100	60 %

4.2 Niveles de desempeño por criterio

Nivel	Rigor técnico	Sustento y reproducibilidad	Comunicación
Sobresaliente (90 a 100 %)	Descubre problemas no evidentes, cuantifica su impacto y propone solución robusta	Todo reproducible, supuestos explícitos, pruebas automáticas	Claro para un público no técnico, con priorización
Satisfactorio (70 a 89 %)	Resuelve lo solicitado con métodos adecuados	Reproducible con pequeños ajustes	Claro, aunque sin priorización
En desarrollo (50 a 69 %)	Aplica técnicas sin verificar sus supuestos	Parcialmente reproducible	Descriptivo, poco accionable
Insuficiente (<50 %)	Errores conceptuales o fuga de información	No reproducible	Confuso o sin conclusiones

4.3 Señales de alerta (*red flags*)

- Eliminar o imputar valores centinela o extremos sin analizarlos ni documentarlos.
- Dividir los datos de forma aleatoria para validar series de tiempo.
- Reportar una sola métrica sin modelo de referencia.
- Interpretar correlación como causalidad, o ignorar el ciclo diurno compartido.
- Confiar ciegamente en la columna *calidad* sin cuestionarla.
- Dashboard con gráficos decorativos, ejes truncados o mapas de calor sin unidades ni fecha de actualización, o que oculta los huecos de datos interpolándolos sin avisar.
- Mostrar la dirección del viento como una serie lineal de 0 a 360 grados sin tratar su circularidad.
- Respuestas genéricas que no citan los datos ni las normas solicitadas.

4.4 Sustentación (máximo 10 minutos)

Cada candidato sustenta su trabajo después de la evaluación, **por orden de envío** del correo. Se sugiere la siguiente distribución del tiempo:

Segmento	Minutos	Contenido
Presentación	5	Hallazgos principales, decisiones de modelado y demostración del dashboard
Preguntas del evaluador	4	Defensa de un umbral de calidad o de una decisión metodológica
Cierre	1	Qué haría con más tiempo

Escenario sugerido para la fase de preguntas: *“Una estación comienza a reportar valores plausibles pero congelados durante 48 horas y un cliente institucional ya descargó los datos. ¿Qué hace?”*